

Aprendizaje automatizado

CLASIFICADOR BAYESIANO INGENUO


Gibran Fuentes-Pineda

Febrero 2023

Clasificación

- Salida discreta o categórica (cualitativa)
- Conjunto de ejemplos

$$\mathcal{D} = \left\{ \left(\mathbf{x}^{(1)}, y^{(1)} \right), \left(\mathbf{x}^{(2)}, y^{(2)} \right), \dots, \left(\mathbf{x}^{(n)}, y^{(n)} \right) \right\}$$



Ejemplo de clasificación

- Clasificar sub-especies de la flor Iris basado en el ancho y largo de su pétalo

$$\mathcal{D} = \{([1.4, 0.2], 0), ([1.7, 0.4], 0), \dots, ([4.7, 1.4], 1), ([4.5, 1.5], 1), \dots\}$$

Ancho	Largo	Especie
1.4	0.2	Setosa
1.7	0.4	Setosa
1.5	0.1	Setosa
⋮	⋮	⋮
4.7	1.4	Versicolor
4.5	1.5	Versicolor
3.3	1.0	Versicolor
⋮	⋮	⋮

Características o
atributo

Respuesta

Setosa



Versicolor



Imagen tomada de https://en.wikipedia.org/wiki/Iris_flower_data_set

Clasificador bayesiano ingenuo: modelo generativo

- Modela distribución conjunta de atributos y clases $P(x_1, \dots, x_d, y)$, asumiendo independencia condicional de los atributos dada la clase
- **Independencia condicional:** X y Y son condicionalmente independientes dado Z si

$$P(X, Y|Z) = P(X|Z)P(Y|Z)$$


$$P(X|Y, Z) = P(X|Z)$$

- En el clasificador bayesiano ingenuo, la probabilidad conjunta está dada por


$$P(x_1, \dots, x_d, y) = \left(\prod_{j=1}^d P(x_j|y = c) \right) P(y = c)$$

Clasificador bayesiano ingenuo: representación gráfica

- El clasificador bayesiano ingenuo se puede representar como un modelo gráfico probabilista simple



- De forma más compacta en notación de placas:



Clasificador bayesiano ingenuo: predicción

- Para obtener la probabilidad de cada clase para un nuevo dato $\tilde{\mathbf{x}} = [\tilde{x}_1, \dots, \tilde{x}_d]$ usamos teorema de bayes

$$P(y = c | \tilde{x}_1, \dots, \tilde{x}_d) = \frac{P(\tilde{x}_1, \dots, \tilde{x}_d | y = c) P(y = c)}{P(\tilde{x}_1, \dots, \tilde{x}_d)}$$

- Debido a que

$$\left(\prod_{j=1}^d P(\tilde{x}_j | y = c) \right) P(y = c) \propto P(y = c | \tilde{x}_1, \dots, \tilde{x}_d)$$

- Podemos obtener la clase más probable como¹:

$$\hat{y} = \arg \max_y \left(\prod_{j=1}^d P(\tilde{x}_j | y = c) \right) P(y = c)$$

¹En algunas aplicaciones se requiere conocer las probabilidades para la toma de decisiones, por lo que es necesario calcular $P(\tilde{x}_1, \dots, \tilde{x}_d)$

- Considera n correos electrónicos representados como bolsas de palabras y sus correspondientes etiquetas $\mathcal{X} = \{(\mathbf{x}^{(1)}, y^{(1)}), \dots, (\mathbf{x}^{(n)}, y^{(n)})\}$
 - Vectores $\mathbf{x}^{(i)} = [x_1^{(i)}, \dots, x_d^{(i)}]$
 - $x_j^{(i)}$ es el número de veces que la palabra j ocurre en el correo i ($x_j^{(i)} \in [0, 1]$ si el esquema es binario)

Bolsas de palabras

- Conjunto de documentos

d_1 *Ella toma café y él toma mate*

d_2 *Ella toma notas mientras toma café*

- Matriz documento-término

	café	él	ella	mate	mientras	notas	toma	y
d_1	1	1	1	1	0	0	1	1
d_2	1	0	1	0	1	1	1	0

- Bolsas de palabras

- $d_1 = \{\text{café, él, ella, mate, toma, y}\}$

- $d_2 = \{\text{café, ella, notas, mientras, toma}\}$

Matriz documento-término

- Conjunto de documentos

d_1 Ella $\underbrace{\text{toma}}_{w_4}$ $\underbrace{\text{café}}_{w_1}$ y él $\underbrace{\text{toma}}_{w_4}$ $\underbrace{\text{mate}}_{w_2}$

d_2 Ella $\underbrace{\text{toma}}_{w_4}$ $\underbrace{\text{notas}}_{w_3}$ mientras $\underbrace{\text{toma}}_{w_4}$ $\underbrace{\text{café}}_{w_1}$

- Matriz documento-término **sin palabras vacías**

	café	mate	notas	toma
d_1	1	1	0	1
d_2	1	0	1	1

- Bolsas de palabras binaria (conjunto)
 - $d_1 = \{1, 2, 4\}$
 - $d_2 = \{1, 3, 4\}$

Matriz documento-término

- Conjunto de documentos

d_1 Ella $\underbrace{\text{toma}}_{w_4}$ $\underbrace{\text{café}}_{w_1}$ y él $\underbrace{\text{toma}}_{w_4}$ $\underbrace{\text{mate}}_{w_2}$

d_2 Ella $\underbrace{\text{toma}}_{w_4}$ $\underbrace{\text{notas}}_{w_3}$ mientras $\underbrace{\text{toma}}_{w_4}$ $\underbrace{\text{café}}_{w_1}$

- Matriz documento-término **sin palabras vacías con frecuencias**

	w_1	w_2	w_3	w_4
d_1	1	1	0	2
d_2	1	0	1	2

- Bolsas de palabras con frecuencia
 - $d_1 = \{1, 2, 4, 4\}$
 - $d_2 = \{1, 3, 4, 4\}$

Clasificador bayesiano ingenuo

- Presuponiendo esquema binario y clasificación binaria:

$$x_j \sim \text{Ber}(q_j), j = 1, \dots, d$$

$$y \sim \text{Ber}(q_y)$$

- Entrenamiento: se estiman los parámetros q_1, \dots, q_d condicionadas a las clases ($y = 0$ y $y = 1$) y el parámetro de la distribución a priori de la clase q_y
- Predicción: dado un nuevo documento $\tilde{\mathbf{x}} = [\tilde{x}_1, \dots, \tilde{x}_d]$, podemos obtener su clase más probable usando los parámetros estimados

$$\hat{y} = \arg \max_y \left(\prod_{j=1}^d \text{Ber}(x_j; \hat{q}_j) \right) \text{Ber}(y; \hat{q}_y)$$