

# Aprendizaje automatizado

## REGRESIÓN LOGÍSTICA


---

Gibran Fuentes Pineda

Febrero 2023

# Clasificación

- Salida discreta (cualitativa)
- Ejemplos: detección de spam, reconocimiento de rostros, etc.



# Ejemplo de clasificación

- Clasificar sub-especies de la flor Iris basado en el ancho y largo de su pétalo

Ancho	Largo	Especie
1.4	0.2	Setosa
1.7	0.4	Setosa
1.5	0.1	Setosa
⋮	⋮	⋮
4.7	1.4	Versicolor
4.5	1.5	Versicolor
3.3	1.0	Versicolor
⋮	⋮	⋮

Características o  
atributo

Respuesta

Setosa



Versicolor



Tomada de [https://en.wikipedia.org/wiki/Iris\\_flower\\_data\\_set](https://en.wikipedia.org/wiki/Iris_flower_data_set)

# Clasificación: el caso binario

- En regresión lineal tenemos

$$P(y|\mathbf{x}, \boldsymbol{\theta}, \sigma^2) = \mathcal{N}(y|f_{\boldsymbol{\theta}}(\mathbf{x}, \boldsymbol{\theta}), \sigma^2)$$

- ¿Cómo podemos extender este modelo para la clasificación binaria?

# Clasificación: el caso binario

- En regresión lineal tenemos

$$P(y|\mathbf{x}, \boldsymbol{\theta}, \sigma^2) = \mathcal{N}(y|f_{\boldsymbol{\theta}}(\mathbf{x}, \boldsymbol{\theta}), \sigma^2)$$


- ¿Cómo podemos extender este modelo para la clasificación binaria?
- Modelo de regresión logística

$$P(y|\mathbf{x}, \boldsymbol{\theta}) = \text{Ber}(y|\text{sigm}(\boldsymbol{\theta}^\top \mathbf{x}))$$

# La función logística

- La función sigmoide o logística está dada por

$$\text{sigm}(z) = \frac{1}{1 + \exp(-z)}$$



# Estimador de máxima verosimilitud para regresión logística

- Tomando el negativo de la verosimilitud logarítmica

$$NVL(\boldsymbol{\theta}) = - \sum_{i=1}^n \{y^{(i)} \log q^{(i)} + (1 - y^{(i)}) \log(1 - q^{(i)})\} = E(\boldsymbol{\theta})$$

donde  $E(\boldsymbol{\theta})$  se conoce como *entropía cruzada binaria* y  
 $q^{(i)} = \text{sigm}(\boldsymbol{\theta}^\top \mathbf{x}^{(i)})$

# Estimador de máxima verosimilitud para regresión logística

- Tomando el negativo de la verosimilitud logarítmica

$$NVL(\boldsymbol{\theta}) = - \sum_{i=1}^n \{y^{(i)} \log q^{(i)} + (1 - y^{(i)}) \log(1 - q^{(i)})\} = E(\boldsymbol{\theta})$$

donde  $E(\boldsymbol{\theta})$  se conoce como *entropía cruzada binaria* y  $q^{(i)} = \text{sigm}(\boldsymbol{\theta}^\top \mathbf{x}^{(i)})$

- No hay solución cerrada, podemos entrenar usando descenso por gradiente

$$\nabla E(\boldsymbol{\theta}) = \sum_{i=1}^n (q^{(i)} - y^{(i)}) \cdot \mathbf{x}^{(i)} = \mathbf{X}^\top (\mathbf{q} - \mathbf{y})$$




- Al igual que en regresión lineal la regularización puede ayudar a evitar el sobreajuste
- La función de error y el gradiente están dados por

$$\begin{aligned}\tilde{E}(\boldsymbol{\theta}) &= E(\boldsymbol{\theta}) + \lambda \|\boldsymbol{\theta}\|_2^2 \\ \nabla \tilde{E}(\boldsymbol{\theta}) &= \nabla E(\boldsymbol{\theta}) + 2\lambda \boldsymbol{\theta}\end{aligned}$$


# Clasificación multi-clase: uno vs el resto

- Un clasificador binario entre cada clase y el resto




# Clasificación multi-clase: uno vs el resto

- Un clasificador binario entre cada clase y el resto




# Clasificación multi-clase: uno vs el resto

- Un clasificador binario entre cada clase y el resto




# Clasificación multi-clase: uno vs el resto

- Un clasificador binario entre cada clase y el resto




# Clasificación multi-clase: uno vs el resto

- Un clasificador binario entre cada clase y el resto




# Clasificación multi-clase: uno vs uno

- Un clasificador binario entre cada par de clases



# Clasificación multi-clase: uno vs uno


- Un clasificador binario entre cada par de clases





# Clasificación multi-clase: uno vs uno

- Un clasificador binario entre cada par de clases



# Clasificación multiclase: regresión logística multinomial

- Extensión de la regresión logística para múltiples clases

$$\begin{aligned} P(y|\mathbf{x}, \boldsymbol{\Theta}) &= \text{Cat}(y|\text{softmax}(\boldsymbol{\Theta}^\top \mathbf{x})_k) \\ &= \prod_{k=1}^K \text{softmax}(\boldsymbol{\Theta}^\top \mathbf{x})_k^{[y=k]} \end{aligned}$$

# Clasificación multiclase: regresión logística multinomial

- Extensión de la regresión logística para múltiples clases

$$\begin{aligned} P(y|\mathbf{x}, \Theta) &= \text{Cat}(y|\text{softmax}(\Theta^\top \mathbf{x})_k) \\ &= \prod_{k=1}^K \text{softmax}(\Theta^\top \mathbf{x})_k^{[y=k]} \end{aligned}$$

- donde  $\mathbf{x} = [1, x_1, \dots, x_d]$ ,  $[y = k]$  son los corchetes de Iverson,  $\Theta \in \mathbb{R}^{d \times K}$ ,  $\Theta^\top \mathbf{x} \in \mathbb{R}^K$  y  $\text{softmax}$  es una generalización de la función logística

$$\text{softmax}(\mathbf{z})_k = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}} = \frac{e^{z_k - \max(\mathbf{z})}}{\sum_{j=1}^K e^{z_j - \max(\mathbf{z})}}$$

# EMV para regresión logística multinomial

- Tomando el negativo de la verosimilitud logarítmica

$$NVL(\Theta) = - \sum_{i=1}^n \sum_{k=1}^K [y^{(i)} = k] \log q_k^{(i)} = E(\Theta)$$

- donde

$$q_k^{(i)} = \text{softmax}(\Theta^\top \mathbf{x}^{(i)})_k$$

- A  $E(\Theta)$  se le como *entropía cruzada categórica*.

# EMV para regresión logística multinomial

- Tomando el negativo de la verosimilitud logarítmica

$$NVL(\boldsymbol{\Theta}) = - \sum_{i=1}^n \sum_{k=1}^K [y^{(i)} = k] \log q_k^{(i)} = E(\boldsymbol{\Theta})$$

- donde

$$q_k^{(i)} = \text{softmax}(\boldsymbol{\Theta}^\top \mathbf{x}^{(i)})_k$$

- A  $E(\boldsymbol{\Theta})$  se le como *entropía cruzada categórica*.
- Podemos entrenar modelos usando descenso por gradiente

$$\nabla E(\boldsymbol{\theta})_k = \sum_{i=1}^n (q_k^{(i)} - [y^{(i)} = k]) \cdot \mathbf{x}^{(i)}$$

## ¿Cómo representamos múltiples clases?

- **Sólo un valor:** se representa por una variable discreta  $y$  que puede tomar los valores  $1, \dots, K$ . Por ej. si tenemos 4 clases, representamos la clase 2 por  $y = 2$

## ¿Cómo representamos múltiples clases?

- **Sólo un valor:** se representa por una variable discreta  $y$  que puede tomar los valores  $1, \dots, K$ . Por ej. si tenemos 4 clases, representamos la clase 2 por  $y = 2$
- **1-de-K:** cada clase se representa por un vector binario  $\mathbf{y}$  de  $K$  dimensiones con 1 sólo en la posición de la clase. Siguiendo el mismo ejemplo tenemos

$$\mathbf{y} = [0, 1, 0, 0]$$