

# Aprendizaje automatizado

CAMPOS ALEATORIOS DE MARKOV


---

Gibran Fuentes-Pineda

Abril 2023

# Campos aleatorios de Markov (MRFs)


- Factorización de la distribución conjunta e independencias condicionales se representan con grafos no dirigidos



Tomada de PRML (Bishop 2009)

# Cobija de Markov para MRFs

- Cualquier nodo es condicionalmente independiente de cualquier otro nodo en el grafo dado únicamente sus vecinos




Tomada de PRML (Bishop 2009)

- Distribución conjunta se descompone de acuerdo a funciones sobre los “cliques” del grafo

$$P(x_i, x_j | \mathbf{x}_{\setminus \{i,j\}}) = P(x_i | \mathbf{x}_{\setminus \{i,j\}}) P(x_j | \mathbf{x}_{\setminus \{i,j\}})$$

# Cliques

- Un **clique**  $c$  es un subconjunto de nodos completamente conectados



Tomada de PRML (Bishop 2009)

# Probabilidad conjunta en MRFs

- $P(\mathbf{x}) > 0$  satisface las propiedades de independencia condicional de un grafo no dirigido  $\mathcal{G}$  si y sólo si puede representarse como un producto de factores, uno por clique máximo, es decir

$$P(\mathbf{x}) = \frac{1}{Z} \prod_{\mathcal{C}} \psi_{\mathcal{C}}(\mathbf{x}_{\mathcal{C}})$$

donde  $\mathcal{C}$  es el conjunto de todos los cliques máximos de  $\mathcal{G}$ ,  $\psi_{\mathcal{C}}(\mathbf{x}_{\mathcal{C}})$  se conocen como funciones potencial y  $Z$  es la función de partición dada por

$$Z \triangleq \sum_{\mathbf{x}} \prod_{\mathcal{C}} \psi_{\mathcal{C}}(\mathbf{x}_{\mathcal{C}})$$

- Como  $P(\mathbf{x}) > 0$ , las funciones potencial se pueden expresar como exponenciales


$$\psi_C(\mathbf{x}_C) = \exp(-E(\mathbf{x}_C))$$

donde  $E(\mathbf{x}_C)$  es la función de energía y la representación exponencial se conoce como distribución de Boltzmann


- La distribución conjunta está dada por el producto de funciones potencial, por lo que la energía total se obtiene sumando las energías de cada clique máximo

# MRF para quitar ruido en una imagen binaria (1)

Original ( $x_i \in \{-1, +1\}$ )




Ruidosa ( $y_i \in \{-1, +1\}$ )



Imágenes tomadas de Bishop, *Pattern Recognition and Machine Learning*, 2006.

## MRF para quitar ruido en una imagen binaria (2)

- Presuposiciones
  - Ruido se genera cambiando el signo de la imagen original
  - Signo de pixel  $x_i$  en imagen original se correlaciona con el de sus vecinos  $x_j$  y con el del pixel  $y_i$  de imagen ruidosa
- MRF
  - Nodos corresponden a pixeles en imagen original y ruidosa
  - Cliques máximos entre cada par de pixeles vecinos ( $\{x_i, x_j\}$ ) y entre cada pixel de imagen original y ruidosa ( $\{x_i, y_i\}$ )



Imágenes tomadas de Bishop, *Pattern Recognition and Machine Learning*, 2006.



## MRF para quitar ruido en una imagen binaria (3)

- Funciones de energía
  - Para  $\{x_i, x_j\}$ :  $-\beta x_i x_j$
  - Para  $\{x_i, y_i\}$ :  $-\eta x_i y_i$
  - Preferencia a un signo:  $h x_i$
- Energía total


$$E(\mathbf{x}, \mathbf{y}) = h \sum_i x_i - \beta \sum_{\{i,j\}} x_i x_j - \eta \sum_i x_i y_i$$

- Distribución conjunta

$$P(\mathbf{x}, \mathbf{y}) = \frac{1}{Z} e^{-E(\mathbf{x}, \mathbf{y})}$$

## MRF para quitar ruido en una imagen binaria (4)

- Algoritmo *iterated conditional modes* (ICM) para obtener  $P(\mathbf{x}|\mathbf{y})$ 
  1. Inicializa  $x_i = y_i$
  2. Calcula la energía dado que un nodo  $x_i = +1$  y  $x_i = -1$  y fija el valor con menor energía.
  3. Repite 2 hasta cumplir criterio de paro



## Conversión de redes bayesianas a MRFs

- Nos debemos asegurar que el conjunto de variables que aparecen en cada distribución condicional sean miembros de al menos un clique
- Para nodos de una red bayesiana con más de un padre es necesario agregar aristas entre los nodos padre en el MRF (**moralización**)

# Conversión de redes bayesianas a MRFs

- Cadenas en redes bayesianas

$$P(\mathbf{x}) = P(x_1)P(x_2|x_1)P(x_3|x_2) \cdots P(x_n|x_{n-1})$$



Tomada de PRML (Bishop 2009)

# Conversión de redes bayesianas a MRFs

- Cadenas en redes bayesianas

$$P(\mathbf{x}) = P(x_1)P(x_2|x_1)P(x_3|x_2) \cdots P(x_n|x_{n-1})$$



Tomada de PRML (Bishop 2009)

- Cadenas en MRFs


$$P(\mathbf{x}) = \frac{1}{Z} \psi_{1,2}(x_1, x_2) \psi_{2,3}(x_2, x_3) \cdots \psi_{n,n-1}(x_{n-1}, x_n)$$




Tomada de PRML (Bishop 2009)

## Conversión: otra topología

Red bayesiana




MRF



# ¿Que distribuciones podemos representar?

- Redes bayesianas vs MRFs




Tomada de PRML (Bishop 2009)

# Conversión: limitaciones

- Algunas redes bayesianas no se pueden representar como MRFs

$$A \perp\!\!\!\perp B \mid \emptyset$$

$$A \not\perp\!\!\!\perp B \mid C$$



Tomada de PRML (Bishop 2009)




# Conversión: limitaciones

- Algunas redes bayesianas no se pueden representar como MRFs

$$A \perp\!\!\!\perp B \mid \emptyset$$

$$A \not\perp\!\!\!\perp B \mid C$$




Tomada de PRML (Bishop 2009)

- Y viceversa

$$A \not\perp\!\!\!\perp B \mid \emptyset$$

$$C \perp\!\!\!\perp D \mid A \cup B$$

$$A \perp\!\!\!\perp B \mid C \cup D$$



Tomada de PRML (Bishop 2009)