

Aprendizaje automatizado


AGRUPAMIENTO

Gibran Fuentes Pineda

Abril 2023

Aprendizaje sin supervisión


- Ejemplos sólo contienen entradas sin salidas deseadas
- Algunas tareas: el agrupamiento y el descubrimiento de patrones



- Busca encontrar la estructura escondida de los datos sin necesitar etiquetas


Agrupamiento

- Objetivo: agrupar ejemplos en base a su proximidad
- Criterios: por conectividad y por compacidad



Ejemplo de <http://scikit-learn.org>

Diferentes algoritmos de agrupamiento



Ejemplo de <http://scikit-learn.org>

Agrupamiento por K-medias

- Divide ejemplos en K grupos, asignando cada ejemplo al grupo con el centroide más cercano
- Busca los K centroides que minimicen

$$E[\boldsymbol{\mu}_1, \dots, \boldsymbol{\mu}_K] = \sum_{i=1}^n \sum_{k=1}^K r_{ik} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2$$

donde $r_{ik} = 1$ si $\boldsymbol{\mu}_k$ es el centroide más cercano a \mathbf{x}_i y $r_{ik} = 0$ en caso contrario

1. Elige K ejemplos aleatoriamente como centroides iniciales




Imagen tomada de Wikipedia (K-means clustering)

Algoritmo de K-medias

1. Elige K ejemplos aleatoriamente como centroides iniciales
2. Asigna cada ejemplo al centroide más próximo




Imagen tomada de Wikipedia (K-means clustering)

Algoritmo de K-medias

1. Elige K ejemplos aleatoriamente como centroides iniciales
2. Asigna cada ejemplo al centroide más próximo
3. Re-calcula los centroides a partir de las asignaciones

$$\mu_k = \frac{1}{n_k} \sum_{i=1}^n r_{ik} \mathbf{x}_i, n_k = \sum_{i=1}^n r_{ik}, k = 1, \dots, K$$




Imagen tomada de Wikipedia (K-means clustering)

Algoritmo de K-Means

1. Elige K ejemplos aleatoriamente como centroides iniciales
2. Asigna cada ejemplo al centroide más próximo
3. Re-calcula los centroides a partir de las asignaciones
4. Repite hasta cumplir criterio de convergencia (por ej. que E no disminuya)




Imagen tomada de Wikipedia (K-means clustering)

Agrupamiento de imágenes de dígitos con K-medias


- El algoritmo de K-medias genera una partición del espacio representado por el diagrama de Voronoi en el que cada punto está asociado al centroide más próximo.



Ejemplo de <http://scikit-learn.org>

K-medias por minilotes¹ vs K-medias

- Actualiza centroides y asignaciones usando un ejemplo o un subconjunto pequeño de ejemplos a la vez



Ejemplo de <http://scikit-learn.org>

¹D. Sculley. *Web-Scale K-Means Clustering*, 2010.

Agrupamiento jerárquico

- Construye de forma gradual una jerarquía de grupos siguiendo un criterio dado
 - **Aglomerativo:** empieza considerando cada dato como un grupo y va mezclando grupos
 - **Divisivo:** empieza considerando todos los datos como un solo grupo y lo va dividiendo
- Dados dos grupos $\{\mathcal{G}_a, \mathcal{G}_b\}$, algunos criterios son
 - Mínimo o simple: $\min \{dist(\mathbf{x}^{(i)}, \mathbf{x}^{(j)}) : \mathbf{x}^{(i)} \in \mathcal{G}_a, \mathbf{x}^{(j)} \in \mathcal{G}_b\}$
 - Completo o máximo: $\max \{dist(\mathbf{x}^{(i)}, \mathbf{x}^{(j)}) : \mathbf{x}^{(i)} \in \mathcal{G}_a, \mathbf{x}^{(j)} \in \mathcal{G}_b\}$
 - Promedio

$$\frac{1}{|\mathcal{G}_a| |\mathcal{G}_b|} \sum_{\mathbf{x}^{(i)} \in \mathcal{G}_a} \sum_{\mathbf{x}^{(j)} \in \mathcal{G}_b} dist(\mathbf{x}^{(i)}, \mathbf{x}^{(j)})$$

- Mínima varianza: elige el par de grupos en el que la varianza intergrupar se incremente menos

Dendogramas

- Diagrama jerárquico que muestra los agrupamientos en distintos niveles




Imagen generada por ejemplo de scikit-learn

Agrupamiento espectral

- Se calcula la matriz laplaciana L a partir de la matriz de adyacencia o afinidad A de la siguiente manera

- Sin normalizar

$$L = D - A$$

- Normalizada simétrica

$$L_{\text{sim}} = D^{-1/2} L D^{-1/2} = I - D^{-1/2} A D^{-1/2}$$

- Caminata aleatoria

$$L_{\text{ca}} = D^{-1} L = I - D^{-1} A$$

- Se realiza el agrupamiento usando K-medias sobre los puntos representados por los K eigenvectores con mayores eigenvalores de la matriz laplaciana L


- Consideremos una red como grafo no dirigido $\mathcal{G}(\mathcal{V}, \mathcal{E})$

$$\text{Corte}(\mathbf{A}) = \sum_{i \in \mathbf{A}, j \notin \mathbf{A}} w_{i,j}$$

donde \mathbf{A} es un conjunto de vértices del grafo y $w_{i,j}$ denota el peso de la arista entre los vértices i y j .

Partición del grafo


- Objetivo: dividir los vértices en dos grupos disjuntos tal que
 - Se maximice el número de conexiones entre vértices del mismo grupo
 - Se minimice el número de conexiones entre vértices de grupos distintos



Representación de grafos: matriz de adyacencia

- Matriz de adyacencia A


$$A = \begin{bmatrix} 0 & 1 & 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 1 & 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 1 & 1 & 1 \\ 0 & 0 & 0 & 1 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 & 1 & 0 & 1 \\ 0 & 0 & 0 & 1 & 0 & 1 & 0 \end{bmatrix}$$



Representación de grafos: matriz de grado

- Matriz de grado G


$$G = \begin{bmatrix} 2 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 3 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 2 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 4 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 2 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 3 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 2 \end{bmatrix}$$



Representación de grafos: matriz laplaciana

- Laplaciana $L = G - A$

$$L = \begin{bmatrix} 2 & -1 & -1 & 0 & 0 & 0 & 0 \\ -1 & 3 & -1 & -1 & 0 & 0 & 0 \\ -1 & -1 & 2 & 0 & 0 & 0 & 0 \\ 0 & -1 & 0 & 4 & -1 & -1 & -1 \\ 0 & 0 & 0 & -1 & 2 & -1 & 0 \\ 0 & 0 & 0 & -1 & -1 & 3 & -1 \\ 0 & 0 & 0 & -1 & 0 & -1 & 2 \end{bmatrix}$$



Eigendecomposición de grafos

- La idea es analizar el *spectrum* de la matriz laplaciana del grafo
 - Conjunto de eigenvectores $\{\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(K)}\}$ del grafo con sus correspondientes eigenvalores asociados $\Lambda = \{\lambda_1, \dots, \lambda_K\}$, donde $\lambda_1 \leq \lambda_2, \dots, \leq \lambda_K$
- Dada la matriz laplaciana \mathbf{L} de un grafo \mathcal{G} , su primer eigenvalor λ_1 y correspondiente eigenvector son
 - $\lambda_1 = 0$ y $\mathbf{x} = [1, 1, \dots, 1]$, por lo que $\mathbf{L} \cdot \mathbf{x} = 0$

Encontrando λ_2 (1)

- Para cualquier matriz de simétrica \mathbf{M}

$$\lambda_2 = \min_{\mathbf{x}} \frac{\mathbf{x}^\top \mathbf{M} \mathbf{x}}{\mathbf{x}^\top \mathbf{x}}$$

- Para una matriz laplaciana \mathbf{L}

$$\begin{aligned} \mathbf{x}^\top \mathbf{L} \mathbf{x} &= \sum_{i=1, j=1}^n L_{i,j} \cdot x_i \cdot x_j = \sum_{i=1, j=1}^n (D_{i,j} - A_{i,j}) \cdot x_i \cdot x_j \\ &= \sum_{i=j} D_{i,j} \cdot x_i^2 - \sum_{(i,j) \in E} 2 \cdot x_i \cdot x_j = \sum_{(i,j) \in E} [x_i^2 + x_j^2 - 2 \cdot x_i \cdot x_j] \\ &= \sum_{(i,j) \in E} [x_i - x_j]^2 \end{aligned}$$

Encontrando λ_2 (2)

- Restricciones

- \mathbf{x} es un vector unitario, lo que implica que

$$\sum_{i=1}^n x_i^2 = 1$$

- \mathbf{x} es ortogonal a $[1, 1, \dots, 1]$ (primer eigenvector); en consecuencia

$$\sum_{i=1}^n x_i \cdot 1 = \sum_{i=1}^n x_i = 0$$

- Por lo tanto, el problema de minimización busca valores x_i con pocas aristas que crucen por cero

$$\lambda_2 = \min_{x_i} \frac{\sum_{(i,j) \in E} [x_i - x_j]^2}{\sum_{i=1}^n x_i^2}$$

Corte óptimo

- Problema: cortar el grafo \mathcal{G} en dos subgrafos \mathcal{A} y \mathcal{B}
 - Se representa por un vector \mathbf{x} , donde un elemento tiene un valor 1 si pertenece a \mathcal{A} y -1 si pertenece a \mathcal{B}
- Se busca un vector no trivial

$$\mathbf{x} = \arg \min_{\mathbf{x} \in \{-1, +1\}^n} \sum_{(i,j) \in E} [x_i - x_j]^2$$


- No es posible resolver de forma exacta, por lo que se relaja el problema a

$$\mathbf{x} = \arg \min_{\mathbf{x} \in \mathbb{R}^n} \overbrace{\sum_{(i,j) \in E} [x_i - x_j]^2}^{f(\mathbf{x})}$$

- La solución está dada por el eigenvector asociado al segundo eigenvalor de la matriz laplaciana \mathbf{L}

1. Construir la matriz laplaciana L .
2. Calcular los eigenvalores y eigenvectores de la matriz laplaciana
3. Mapear los vértices a los elementos del eigenvector \mathbf{e} asociado al segundo eigenvalor
4. Ordenar los elementos del vector \mathbf{e}
5. Agrupar vértices dividiendo el vector ordenado en dos
 - Por ejemplo usando el 0 o la mediana.

Partición espectral: otro ejemplo con 2 grupos



$$L = \begin{bmatrix} 3 & -1 & -1 & -1 & 0 & 0 \\ -1 & 2 & -1 & -0 & 0 & 0 \\ -1 & -1 & 3 & 0 & 0 & -1 \\ -1 & 0 & 0 & 3 & -1 & -1 \\ 0 & 0 & 0 & -1 & 2 & -1 \\ 0 & 0 & -1 & -1 & -1 & 3 \end{bmatrix}$$

λ	0	1	2	3	4	5
\mathbf{x}	1	1	-5	-1	-1	-1
	1	2	4	-2	1	0
	1	1	1	3	-1	1
	1	-1	-5	-1	1	1
	1	-2	4	-2	-1	0
	1	-1	1	3	1	-1

Partición espectral: ejemplo con 2 grupos





Figura tomada de diapositivas por J. Leskovec, A. Rajaraman, J. Ullman: Mining of Massive Datasets, <http://www.mmms.org>

Partición espectral: ejemplo con 4 grupos (1)




Figura tomada de diapositivas por J. Leskovec, A. Rajaraman, J. Ullman: Mining of Massive Datasets, <http://www.mmms.org>

Partición espectral: ejemplo con 4 grupos (2)





Figura tomada de diapositivas

por J. Leskovec, A. Rajaraman, J. Ullman: Mining of Massive Datasets, <http://www.mmds.org>

Partición de grafos en K grupos

- Partición recursiva
 - Divide el grafo en dos grupos, posteriormente se aplica el algoritmo en cada grupo generando a su vez dos subgrupos cada uno y así sucesivamente.
- Múltiples eigenvectores
 - Se representa cada vértice usando los elementos de múltiples eigenvectores (asociados a los eigenvalores $\lambda_2, \lambda_3, \dots, \lambda_K$).
 - Se agrupan las representaciones usando algún algoritmo de agrupamiento (por ej. K-medias).

frame