

# Aprendizaje automatizado

## ANÁLISIS DE FACTORES

---

Gibran Fuentes Pineda

Mayo 2023

## Recordando la maldición de la dimensionalidad

- Objetos cada vez más dispersos conforme aumenta el número de dimensiones

# La hipótesis de la variedad

- Ejemplos pueden vivir en una variedad de muchas menores dimensiones que el espacio original





Imagen tomada de Li and Jain, 2005


# Análisis de componentes principales (PCA)

- Proyección ortogonal de un conjunto de vectores
- Genera una nueva vista
- Aplicaciones
  - Visualización
  - Extracción de características
  - Reducción de dimensionalidad
  - Compresión


## Intuición: datos en 2D




## Intuición: datos vistos desde el eje $x$



## Intuición: datos vistos desde el eje $y$




## Intuición: nuevos ejes $u_1$ y $u_2$






## Intuición: datos proyectados sobre el eje $u_1$



## Intuición: datos proyectados sobre el eje $u_2$



- Dado un conjunto de vectores  $\mathbf{X} = \{\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(n)}\}$  de  $d$  dimensiones, el primer componente principal es el vector  $\mathbf{u}_1$  que maximice la varianza de los datos proyectados, donde  $\mathbf{u}_1$  es un vector de  $d$  dimensiones

- La proyección de un vector sobre el componente principal está dado por

$$\hat{\mathbf{x}}^{(i)} = \mathbf{u}_1^\top \mathbf{x}^{(i)}$$

## PCA por máxima varianza (1)

- La proyección de un vector sobre el componente principal está dado por

$$\hat{\mathbf{x}}^{(i)} = \mathbf{u}_1^\top \mathbf{x}^{(i)}$$

- La media de los datos proyectados es  $\mathbf{u}_1^\top \bar{\mathbf{x}}$ , donde

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}^{(i)}$$

## PCA por máxima varianza (1)

- La proyección de un vector sobre el componente principal está dado por

$$\hat{\mathbf{x}}^{(i)} = \mathbf{u}_1^\top \mathbf{x}^{(i)}$$

- La media de los datos proyectados es  $\mathbf{u}_1^\top \bar{\mathbf{x}}$ , donde

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}^{(i)}$$

- La varianza es  $\frac{1}{n} \sum_{i=1}^n [\mathbf{u}_1^\top \mathbf{x}^{(i)} - \mathbf{u}_1^\top \bar{\mathbf{x}}]^2 = \mathbf{u}_1^\top \mathbf{S} \mathbf{u}_1$ , donde

$$\mathbf{S} = \frac{1}{n} \sum_{i=1}^n (\mathbf{x}^{(i)} - \bar{\mathbf{x}})(\mathbf{x}^{(i)} - \bar{\mathbf{x}})^\top$$

## PCA por máxima varianza (2)

- Queremos encontrar el vector  $\mathbf{u}_1$  que maximice la varianza de los datos proyectados  $\mathbf{u}_1^\top \mathbf{S} \mathbf{u}_1$ , con la restricción que  $\mathbf{u}_1^\top \mathbf{u}_1 = 1$

## PCA por máxima varianza (2)

- Queremos encontrar el vector  $\mathbf{u}_1$  que maximice la varianza de los datos proyectados  $\mathbf{u}_1^\top \mathbf{S} \mathbf{u}_1$ , con la restricción que  $\mathbf{u}_1^\top \mathbf{u}_1 = 1$
- Podemos formular esta restricción usando multiplicadores de Lagrange:  $\mathbf{u}_1^\top \mathbf{S} \mathbf{u}_1 + \lambda_1(1 - \mathbf{u}_1^\top \mathbf{u}_1)$



## PCA por máxima varianza (2)

- Queremos encontrar el vector  $\mathbf{u}_1$  que maximice la varianza de los datos proyectados  $\mathbf{u}_1^\top \mathbf{S} \mathbf{u}_1$ , con la restricción que  $\mathbf{u}_1^\top \mathbf{u}_1 = 1$
- Podemos formular esta restricción usando multiplicadores de Lagrange:  $\mathbf{u}_1^\top \mathbf{S} \mathbf{u}_1 + \lambda_1(1 - \mathbf{u}_1^\top \mathbf{u}_1)$
- Derivando e igualando a cero, tenemos

$$\mathbf{S} \mathbf{u}_1 = \lambda_1 \mathbf{u}_1$$

## PCA por máxima varianza (2)

- Queremos encontrar el vector  $\mathbf{u}_1$  que maximice la varianza de los datos proyectados  $\mathbf{u}_1^\top \mathbf{S} \mathbf{u}_1$ , con la restricción que  $\mathbf{u}_1^\top \mathbf{u}_1 = 1$
- Podemos formular esta restricción usando multiplicadores de Lagrange:  $\mathbf{u}_1^\top \mathbf{S} \mathbf{u}_1 + \lambda_1(1 - \mathbf{u}_1^\top \mathbf{u}_1)$

- Derivando e igualando a cero, tenemos

$$\mathbf{S} \mathbf{u}_1 = \lambda_1 \mathbf{u}_1$$

- Esto es,  $\mathbf{u}_1$  es un vector propio de  $\mathbf{S}$ , donde  $\lambda_1 = \mathbf{u}_1^\top \mathbf{S} \mathbf{u}_1$  es su valor propio que se corresponde con la varianza de los datos proyectados

- El siguiente componente principal es el vector propio que maximice la varianza de los datos proyectados entre el conjunto de vectores ortogonales a los que ya han sido elegidos.

Este proceso se realiza de forma incremental hasta obtener los  $K$  componentes principales.

- El conjunto de  $K$  componentes principales forman una base ortonormal de funciones.

# Proyección y reconstrucción componentes principales

- Para proyectar un vector  $\mathbf{x}^{(i)}$  sobre los componentes principales

$$\mathbf{z}^{(i)} = \mathbf{U}^\top [\mathbf{x}^{(i)} - \bar{\mathbf{x}}]$$

donde  $\mathbf{U} = [\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_K]$  es una matriz cuyas columnas se corresponden con los  $K$  componentes principales.

- La reconstrucción está dada por

$$\mathbf{x}_{\text{rec}}^{(i)} = \mathbf{U}\mathbf{z}^{(i)} + \bar{\mathbf{x}}$$

# PCA por vectores y valores propios

- Busca subespacio de  $K$  dimensiones que maximiza varianza (o minimiza error) de los ejemplos
  - Definido por eigenvectores  $\mathbf{u}_1, \dots, \mathbf{u}_K$  con eigenvalores más grandes  $\lambda_1, \dots, \lambda_K$  de la matriz de covarianza







Figura tomada de Wikipedia (*Principal Component Analysis*)

# PCA aplicado a imágenes de rostros

- Componentes principales se toman como base (eigenfaces)
- Nuevos rostros se proyectan en subespacio encontrado para ser comparados



# PCA incremental



Ejemplo de <http://scikit-learn.org>

# Análisis de factores: variables continuas

- Variables latentes continuas  $\mathbf{z} \in \mathbb{R}^K$ , con a priori gaussiana

$$\mathbf{z} \sim \mathcal{N}(\mathbf{z}|\boldsymbol{\mu}_0, \boldsymbol{\Sigma}_0)$$

- Variables observadas continuas  $\mathbf{x} \in \mathbb{R}^d$  con<sup>1</sup>

$$\mathbf{x}|\mathbf{z} \sim \mathcal{N}(\mathbf{U}\mathbf{z} + \boldsymbol{\mu}, \boldsymbol{\Psi})$$

- Distribución sobre  $\mathbf{x}$  está dada por

$$P(\mathbf{x}) = \int P(\mathbf{x}|\mathbf{z})P(\mathbf{z})d\mathbf{z} = \mathcal{N}(\mathbf{x}|\boldsymbol{\mu}, \mathbf{C})$$

$$\text{donde } \mathbf{C} = \mathbf{U}\mathbf{U}^\top + \sigma^2\mathbf{I}$$

---

<sup>1</sup>Cuando  $\boldsymbol{\Psi} = \sigma^2\mathbf{I}$ ,  $\boldsymbol{\mu}_0 = \mathbf{0}$  y  $\boldsymbol{\Sigma}_0 = \mathbf{I}$ , se conoce como *análisis de componentes principales probabilista* (PPCA).



- Presuponiendo  $\sigma^2 = 0$ , se pueden encontrar parámetros de PCA por máxima verosimilitud usando el algoritmo EM

1. Paso E:  $\tilde{\mathbf{Z}} = (\mathbf{U}^\top \mathbf{U})^{-1} \mathbf{U}^\top \tilde{\mathbf{X}}$
2. Paso M:  $\mathbf{U} = \tilde{\mathbf{X}}^\top \tilde{\mathbf{Z}}^\top (\tilde{\mathbf{Z}} \tilde{\mathbf{Z}}^\top)^{-1}$

donde  $\tilde{\mathbf{X}} = \mathbf{X}^\top$

# Análisis de componentes independientes (ICA)

- ICA considera que variables latentes no siguen una distribución gaussiana pero son independientes

$$P(\mathbf{z}) = \prod_{j=1}^d P(z_j)$$

- Aplicación: separación de fuentes ciega




Imagen generado usando ejemplo de <http://scikit-learn.org>

# PCA vs ICA




Imagen generada usando ejemplo de <http://scikit-learn.org>

# Codificación dispersa

- $\mathbf{z}$  tiene más dimensiones que  $\mathbf{x}$
- Apriori de  $\mathbf{z}$  viene de distribución que favorece dispersidad
- $\mathbf{x}$  se aproxima como combinación dispersa de columnas de  $\mathbf{W}$

$$\mathbf{x} = \mathbf{W}\mathbf{z} + \epsilon$$

