

Aprendizaje automatizado


MÁQUINAS DE VECTORES DE SOPORTE

Gibran Fuentes-Pineda

Mayo 2023


Caso 1: Clasificación binaria linealmente separable

- ¿Cómo separamos las clases?




Caso 1: Clasificación binaria linealmente separable

- ¿Qué hiperplano elegimos?




Clasificadores de margen máximo (1)

- El del margen más grande: hiperplanos paralelos a región de decisión que pasan por datos se llaman *vectores de soporte*



Clasificadores de margen máximo (2)



- Consideremos la frontera de decisión generada por \mathbf{w} y una constante c . Dado un punto $\mathbf{x}^{(i)}$, la regla de decisión está definida por


$$\mathbf{w}^T \mathbf{x}^{(i)} \geq c$$

- La cual podemos reescribir como ($b = -c$)

$$\mathbf{w}^T \mathbf{x}^{(i)} + b \geq 0$$

- \mathbf{w} es perpendicular a la frontera de decisión

Clasificadores de margen máximo (3)



- Restricciones

$$\mathbf{w}^\top \mathbf{x}^{(i)} + b \geq 1, \text{ si } y^{(i)} = 1$$

$$\mathbf{w}^\top \mathbf{x}^{(i)} + b \leq -1, \text{ si } y^{(i)} = -1$$

- Sea $y^{(i)} = 1$ para positivos y $y^{(i)} = -1$ para negativos, podemos reescribir


$$y^{(i)} \cdot (\mathbf{w}^\top \mathbf{x}^{(i)} + b) \geq 1$$

$$y^{(i)} \cdot (\mathbf{w}^\top \mathbf{x}^{(i)} + b) - 1 \geq 0$$

- Si $\mathbf{x}^{(i)}$ está exactamente en los hiperplanos de soporte

$$y^{(i)} \cdot (\mathbf{w}^\top \mathbf{x}^{(i)} + b) - 1 = 0$$

Clasificadores de margen máximo (4)



- Dados $x_{pos}^{(i)}$ (ejemplo positivo) y $x_{neg}^{(j)}$ (ejemplo negativo), el margen se puede calcular como

$$\frac{w^T}{\|w\|} \cdot (x_{pos}^{(i)} - x_{neg}^{(j)}) = \frac{2}{\|w\|}$$

- Queremos encontrar la w que maximice el ancho o de forma equivalente minimizar

$$\frac{\|w\|}{2}$$

- Podemos convertir el problema a una optimización con restricciones

$$\begin{aligned} & \underset{\mathbf{w}, b}{\text{mín}} \frac{1}{2} \|\mathbf{w}\|^2 \\ & \text{sujeto a } y^{(i)}(\mathbf{w}^\top \mathbf{x}^{(i)} + b) \geq 1 \end{aligned}$$

donde $y^{(i)} \in \{-1, +1\}$

Optimización con restricciones

- Podemos convertir el problema a una optimización con restricciones

$$\begin{aligned} & \underset{\mathbf{w}, b}{\text{mín}} \frac{1}{2} \|\mathbf{w}\|^2 \\ & \text{sujeto a } y^{(i)}(\mathbf{w}^\top \mathbf{x}^{(i)} + b) \geq 1 \end{aligned}$$

donde $y^{(i)} \in \{-1, +1\}$

- Optimización cuadrática con restricciones lineales y estrictamente convexa con solución única para problemas linealmente separables

Caso 2: No linealmente separables

- Penalizando suavemente clasificaciones erróneas a través de *variables flojas*, $\xi^{(i)} \geq 0, i = 1, \dots, n$

$$\min_{\mathbf{w}, b} \left[C \sum_{i=1}^n \xi^{(i)} + \frac{1}{2} \|\mathbf{w}\|^2 \right]$$

sujeto a $y^{(i)}(\mathbf{w}^\top \mathbf{x}^{(i)} + b) \geq 1 - \xi^{(i)}$




Imagen tomada de Bishop, PRML 2007


- $\xi^{(i)} = 0$, si están del lado correcto
- $\xi^{(i)} = |y^{(i)} - (\mathbf{w}^\top \mathbf{x}^{(i)} + b)|$ para otros puntos

Función de pérdida bisagra


- Error respecto a parámetros está dado por función bisagra

$$B(\hat{y}, y) = \max(0, 1 - \hat{y} \cdot y)$$

$$y = 1$$



$$y = -1$$







Encontrando el clasificador margen máximo

- El problema de optimización

$$\min_{\mathbf{w}, b} \left[C \cdot \sum_{i=1}^n B(\hat{y}^{(i)}, y^{(i)}) + \frac{1}{2} \|\mathbf{w}\|^2 \right]$$

Caso 2: No linealmente separables

- Clasificación con diferentes valores de C



Máquinas de vectores de soporte para regresión

- Extensión que preserva dispersidad en datos para regresión

Máquinas de vectores de soporte para regresión

- Extensión que preserva dispersidad en datos para regresión
- Usa función de pérdida ϵ -sensible

$$E(\hat{y}^{(i)}, y^{(i)}) = \begin{cases} 0 & \text{si } |\hat{y}^{(i)} - y^{(i)}| < \epsilon \\ |\hat{y}^{(i)} - y^{(i)}| - \epsilon & \text{en caso contrario} \end{cases}$$




Imagen tomada de Bishop, PRML 2006

Problema de optimización para regresión

- Se busca resolver

$$\min_{\mathbf{w}, b} \left[C \sum_{i=1}^n E(\hat{y}^{(i)}, y^{(i)}) + \frac{1}{2} \|\mathbf{w}\|^2 \right]$$

- Expresado con variables flojas ξ

$$\min_{\mathbf{w}, b} \left[C \sum_{i=1}^n (\xi^{(i)} + \hat{\xi}^{(i)}) + \frac{1}{2} \|\mathbf{w}\|^2 \right]$$

sujeto a $\hat{y}^{(i)} + \epsilon + \xi^{(i)} \geq y^{(i)}$
 $\hat{y}^{(i)} - \epsilon - \hat{\xi}^{(i)} \leq y^{(i)}$




Imagen tomada de Bishop, PRML 2006